

MANUAL DE INSTALACIÓN Y MONTAJE DE BASES DE DATOS NOSQL (COUCHDB Y ELASTICSEARCH) DE LA DATA PARA LOS APLICATIVOS DEL CLÚSTER DE SOLUCIONES NUVEM CNCFLORA BRASIL

VERSION 1.0 - 01-12-2016





Elaborado Por: Jaime Alberto Gutiérrez Mejía

ÍNDICE

ÍND	NDICE2		
1.	OBJETO DEL DOCUMENTO	3	
2.	PARTICIPANTES	3	
3.	OBJETIVOS	3	
4.	PREPARACIÓN DE LOS DATOS PARA EL PROCESO MIGRATORIO	4	
5.	EJECUCIÓN DEL CLIENTE DE GENERACIÓN DE ARCHIVOS DE CARGUE MASIVO EN COUCHDB Y		
ELA	STICSEARCH	9	
6	REALIZACIÓN DEL CARGUE AL AMRIENTE DE RASES DE DATOS NO RELACIONALES	22	





1. OBJETO DEL DOCUMENTO

Este documento tiene como objeto ilustrar cómo debe realizarse el proceso de cargue de bases de datos noSQL (COUCHDB y ELASTICSEARCH) del conjunto de aplicaciones del clúster NUVEM CNCFLORA BRASIL, con el fin de poder registrar de forma automatizada para el core de soluciones de backoffice de la solución, los datos de las correspondientes bases de categorías (familias) de registros de especies biológicas.

2. PARTICIPANTES

En este proceso tiene principal participación el Administrador Técnico del Sistema, el jefe de gestión de aplicaciones del Instituto Alexander von Humboldt y los participantes del proceso de despliegue y paso a producción.

3. OBJETIVOS

- a) Realizar la preparación de los datos para el cargue al Sistema
- b) Ejecutar el cliente de construcción de los archivos de generación de cargue masiva de registros para COUCHDB y la indización de los mismos con Elasticsearch.
- c) Desarrollar el proceso de cargue de los datos desde la consola del Sistema operativo del ambiente de ejecución
- d) Validar la data cargada en los aplicativos del clúster NUVEM

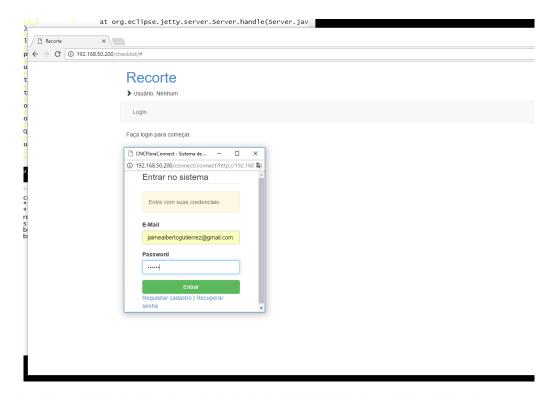




4. PREPARACIÓN DE LOS DATOS PARA EL PROCESO MIGRATORIO

Con el objeto de desarrollar el proceso de migración de datos a la solución de NUVEM CNCFLORA, el usuario deberá preparar la data de las diferentes bases de datos, previa creación de las bases concretas (denominadas en el ambiente de producción RECORTES). Para ello, se deberá ingresar al Sistema por alguna de las dos siguientes vías:

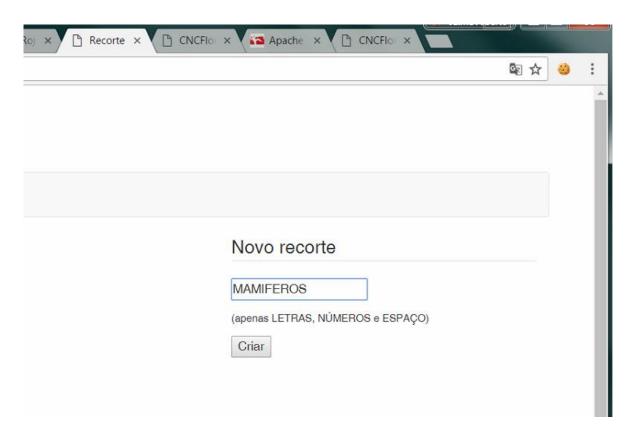
a) VÍA ADMINISTRACIÓN CHECKLIST: Para construir las bases requeridas, el usuario deberá ingresar por el aplicativo Web de LISTA DE CHEQUEO (Checklist) http://192.168.11.67/checklist, autenticarse con el usuario previamente creado desde el aplicativo de gestión de SSO (ENTRYPOINT: http://192.168.11.67/entrypoint/), tal como se muestra a continuación:







Una vez el usuario se autentique se puede proceder a crear la base, escribiendo el nombre de la misma en el formulario Nuevo Recorte:

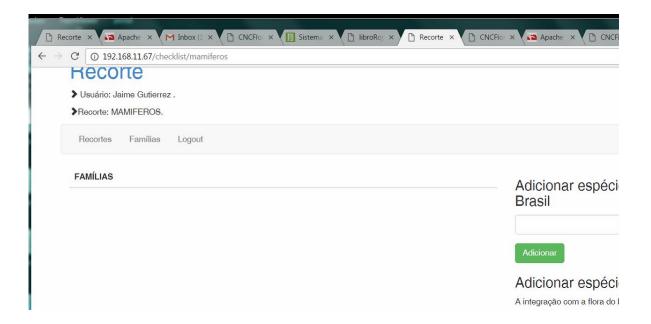






Recortes

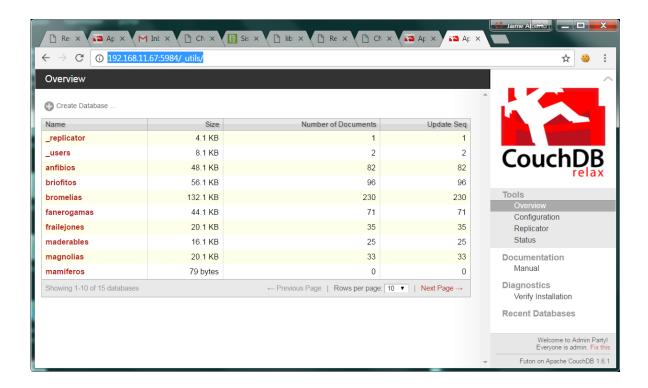
- ANFIBIOS
- BRIOFITOS
- BROMELIAS
- FANEROGAMAS
- FRAILEJONES
- MADERABLES
- MAGNOLIAS
- MAMIFEROS
- MIRISITICACEAE
- ORQUIDEAS



b) VÍA ADMINISTRACIÓN FUTON: Si fuera a realizarse el proceso directamente desde el gestor de base de datos no relacional de COUCHDB, se deberá realizar inicio de sesión en la consola del administrador de la base (FUTON: http://192.168.11.67:5984/ utils/), para poder realizar la creación de las bases de agrupación de especies (familias).







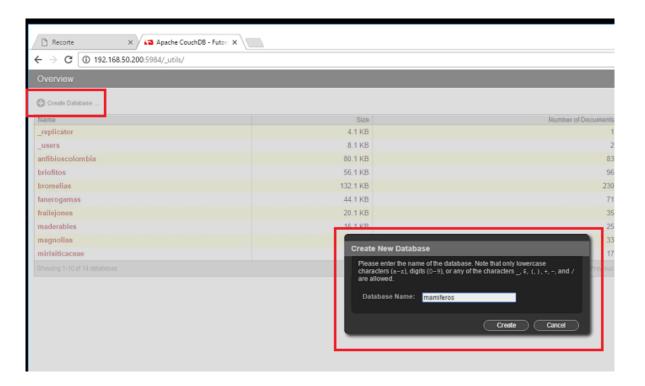
Proceder a iniciar sesión en la parte inferior con las credenciales creadas para el administrador. En el caso de este proyecto:

Username: admin Password: ncc&123x

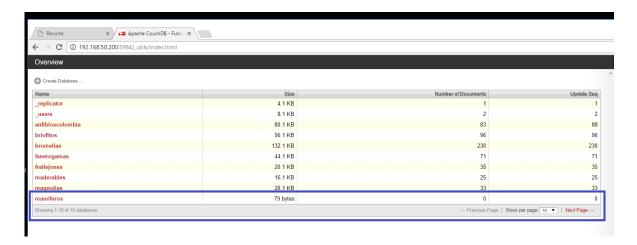
Una vez se haya iniciado sesión en el administrador de FUTON, se procede a escoger la opción CREATE DATABASE y se ingresa el nombre del nuevo recorte o base para CouchdDB.







Automáticamente la base quedará creada y lista para la inserción de nuevos registros de especies biológicas.







5. EJECUCIÓN DEL CLIENTE DE GENERACIÓN DE ARCHIVOS DE CARGUE MASIVO EN COUCHDB Y ELASTICSEARCH

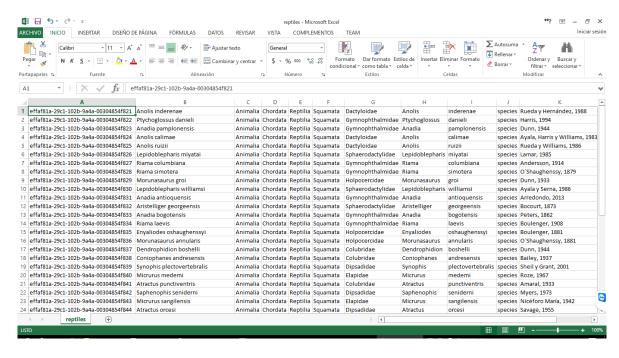
Para el proceso de cargue masivo de registros a las bases de datos del Sistema, se debe preparar la creación de los registros, empleando una plantilla de cargue masiva, la cual incluye los siguientes campos:

Campo	Descripción
id	Identificador único de la Especie
nombreCientifico	Nombre científico nominal de la Especie
kingdom	Familia taxonómica a la que se asocia la especie
phylum	Filum de agrupación de la Especie
clase	Clase de categorización
orden	Orden de distribución
family	Familia de la especie
genus	Genus taxonómico
specificEpithet	Epíteto de clasificación organizacional
rango	Rango de definición (especie, subespecie o derivación)
autor	Autor científico de investigación de la especie
nombreComun	Nombre común o genérico de la especie

Al realizar la organización, el documento debe quedar así:







La estructura del ID debe seguir la nomenclatura que se cita a continuación:

effaf81a-29c1-102b-9a4a-00304854f826

Primer bloque: 8 dígitos hexadecimales
 Segundo bloque: 4 dígitos hexadecimales
 Tercer bloque: 4 dígitos hexadecimales
 Cuarto bloque: 4 dígitos hexadecimales
 Quinto bloque: 12 dígitos hexadecimales

Y cada ID de registro debe ser absolutamente diferente del siguiente, para mantener la integridad de entidad en este modelo.

Una vez el archivo se organice en formato CSV, el paso siguiente, es verificar que no existan los símbolos de tabulación (TAB), punto y coma (;), dado que este último es el separador de campos en el archivo de interface y finalmente las comillas dobles o simples, las cuales deben ser removidas de los registros.





Una vez el archivo esté correspondientemente formado, debe procederse a la ejecución de la aplicación cliente JSE desarrollada para la construcción de forma automatizada de los archivos tanto para COUCHDB como para ElasticSearch. Desde la consola de comandos debe ejecutarse

java -jar GeneradorCouch.jar

Previa validación de la instalación del ambiente JDK de Oracle y del HotSpot correspondiente para la ejecución de aplicaciones

```
C:\WINDOWS\system32\cmd.exe

C:\Users\Jaimiko\Desktop>java -version
java version "1.8.0_73"

Java(TM) SE Runtime Environment (build 1.8.0_73-b02)

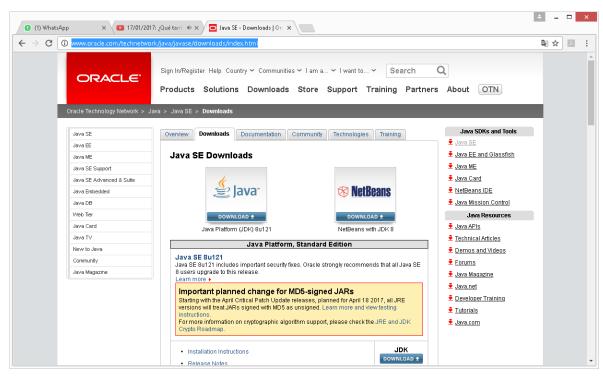
Java HotSpot(TM) 64-Bit Server VM (build 25.73-b02, mixed mode)

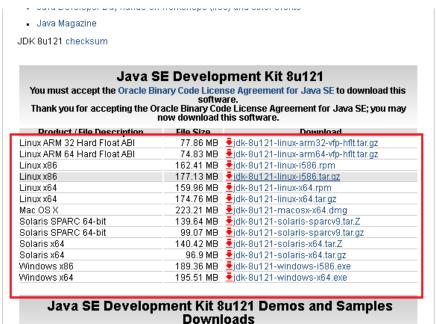
C:\Users\Jaimiko\Desktop>_
```

Si no se puede ejecutar el comando, debe descargarse desde la página oficial de Oracle en la sección DOWNLOADS/JSE TECHNOLOGY (http://www.oracle.com/technetwork/java/javase/downloads/index.html)





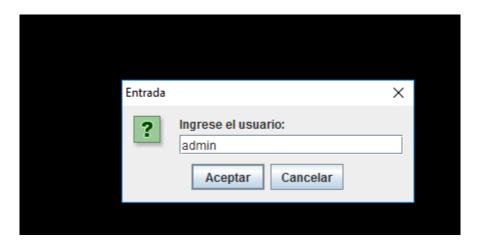








1) Lo primero que hará la aplicación será solicitar el usuario de COUCHDB que está configurado en la consola de FUTON:



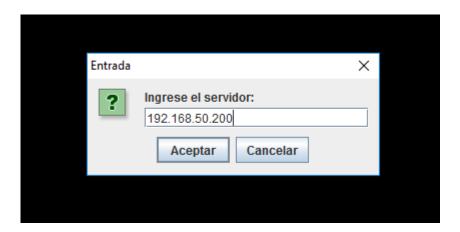
2) Posteriormente se ingresa la contraseña asignada a dicho administrador



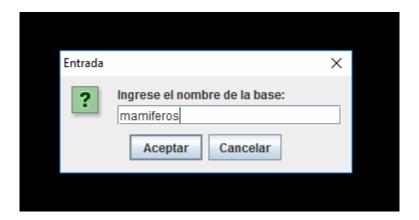
3) Acto seguido debe ingresarse la dirección IP o nombre DNS del servidor que aloja el servicio de CouchDB (No debe ingresarse el puerto, ya que este por defecto está configurado en el 5498).







4) El aplicativo solicitará el nombre de la base (Esta se corresponde al nombre exacto (en letras minúsculas del índice o relatorio creado en COUCHDB) o a través del aplicativo de CHECKLIST.



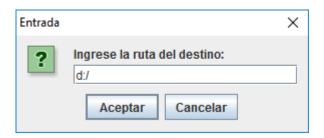
5) El aplicativo solicitará la ruta completa (Linux o Windows) de la ubicación del archivo fuente en formato CSV que contiene el listado completo de todas las especies. Se deberá digitar, como en el ejemplo que se ilustra a continuación:







6) Posteriormente, digitar el path o ruta de destino en donde va a quedar el archivo destino tanto en COUCHDB como en Elasticsearch.







8) Al final de la ejecución de la aplicación, se generarán los correspondientes formatos de cargue de consola CURL, con su notación de acuerdo a los parámetros de entrada:

```
-8a4a-00304854f882", "scientificName": "Bolitoglossa pandi - Brame y Wake, 1963", "scientificNameWithoutAuthorship": "Bolitoglossa pandi", "scientificNameAuthorship": "Brame y Wake, 1963", "family": "Plethodontidae", "taxonRank": "species", "taxonomicStatus": "accepted", "acceptedNameUsage": "Bolitoglossa pandi - Brame y Wake, 1963", "metadata": ("identifier": "fffaf 31a-39c1-202b-8a4a-00304854f882", "type": "taxon", "created": 1479335354, "modified": 1479329478, "creator": "Jaime Alberto Gu tierrez". "contributor": "Jaime Alberto Gu tierrez". "contributor": "Jaime Alberto Gu tierrez". "contact": "jaimealbertogutierrez@gmail.com". "source": "User"}} :url -X POST -d @mamiferos-RegistrosCouchDb1485204497115.json -H "Content-Type: application/json" http://admin:ncc123x@112.168.50.200:5984/mamiferos/ bulk docs luta de salida del archivo de ELASTICSEARCH: d://mamiferos-RegistrosElasticSearch1485204497115.json curl -XPOST 192.168.50.200:9200/mamiferos/_bulk --data-binary @mamiferos-RegistrosElasticSearch1485204497115.json
```

Ejemplo:





Cargue para COUCHDB:

curl -X POST -d @mamiferos-RegistrosCouchDb1485204497115.json -H "Content-Type: application/json" http://admin:ncc123x@192.168.50.200:5984/mamiferos/bulk docs

Cargue del Índice para ELASTICSEARCH:

curl -XPOST 192.168.50.200:9200/mamiferos/_bulk --data-binary @mamiferos-RegistrosElasticSearch1485204497115.json

9) Los archivos resultantes en formato JSON (JAVASCRIPT NOTATION OBJECT), aparecerán en la carpeta de destino:

ArchivosMartillo	19/07/2014 10:15 a	Archivo WinRAR Z	1.054 KB
□ data	10/12/2016 4:53 a	JSON File	19 KB
E Desarrollo	28/04/2016 12:24 a	Archivo WinRAR Z	1.088.512 KB
🗎 eclipse-jee-kepler-SR2-win32	26/04/2014 2:28 p	Archivo WinRAR Z	256.362 KB
■ mamiferos-RegistrosCouchDb1485204497115	23/01/2017 4:17 p	ISON Eile	59 KB
a mamilieros-registros-couchibb 1463204497113	23/01/2017 4:17 p	J3OIN FILE	םא פנ
mamiferos-RegistrosCouchob 1463204497115 mamiferos-RegistrosElasticSearch1485204497115	23/01/2017 4:17 p		60 KB
		JSON File	

Archivo de cargue COUCHDB:





romobatidae", "taxonRank": "species", "taxonomicStatus": "accepted", "acceptedNameUsage": "Allobates ranoides - Boulenger, 1918", "metadata": ("identifier": "fffaf51 1939", "femily": "Bufonidae", "acceptedNameOsage": "AcceptedNameOsage: "AcceptedNam

Archivo de cargue ELASTICSEARCH:





```
{"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f801"}}
:1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f801","scientificName":"Allobates ranoides - Boul
{"index":{"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f802"}}
{"score" :1.0,"taxonID": fffaf81a-39c1-202b-8a4a-00304854f802","scientificName":"Atelopus eusebianus - Riv
{"index":{"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f803"}}
{"_score" :1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f803","scientificName":"Atelopus farci - Lynch, 1
{"index":{"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f804"}}
{"score" :1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f804","scientificName":"Atelopus ignescens - Corn
               {"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f805"}}
:1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f805","scientificName":"Atelopus lozanoi - Osorno
                   _index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f806"}}
  "index":{"
{"_score" :1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f806","scientificName":"Atelopus ebenoides - Rive
{"index":{"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f807"}}
                :1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f807","scientificName":"Atelopus minutulus - Ruíz
 index":{"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f808"}}
               :1.0, "taxonID": "fffaf81a-39c1-202b-8a4a-00304854f808", "scientificName": "Atelopus muisca - Rueda-A
               {"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f809"}}
:1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f809","scientificName":"Atelopus pedimarmoratus -
_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f810"}}
 "_score" :1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f810","scientificName":"Atelopus sernai - Ruíz-Ca
"index":{"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f811"}}
               "index":{"
               {"_index":"mamiferos","_type":"taxon","_id":"fffaf81a-39c1-202b-8a4a-00304854f813"}}
:1.0,"taxonID":"fffaf81a-39c1-202b-8a4a-00304854f813","scientificName":"Rhinella macrorhina - Tru
```

```
llenger, 1918", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f801", "type":"taxon", "created":1475
eusebianus - Rivero y Granados, 1993", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f802", "type
"identifier":"fffaf81a-39c1-202b-8a4a-00304854f803", "type":"taxon", "created":1479335275, "modified":147932933
a, 1849", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f804", "type":"taxon", "created":1479335276
atus":"accepted", "acceptedNameUsage":"Atelopus lozanoi - Osorno-Muñoz, Ardila-Robayo y Ruíz-Carranza, 2001",
3", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f806", "type":"taxon", "created":1479335278, "modi
", "taxonomicStatus":"accepted", "acceptedNameUsage":"Atelopus minutulus - Ruíz-Carranza, Hernandez-Camacho y
ppus muisca - Rueda-Almonacid y Hoyos, 1992", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f808"
s - Rivero, 1963", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f809", "type":"taxon", "created":1
age":"Atelopus sernai - Ruíz-Carranza y Osorno Muñoz, 1994", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a
9", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f811", "type":"taxon", "created":1479335283, "modi
ccepted", "acceptedNameUsage":"Osornophryne percrassa - Ruíz-Carranza y Hernández-Camacho, 1976", "metadata":{
1", "metadata":{"identifier":"fffaf81a-39c1-202b-8a4a-00304854f813", "type":"taxon", "created":1479335285, "modi
```





A continuación se presenta la estructura de cada entrada en el archivo de registro de alimentación de la base para COUCHDB:

```
" id":"fffaf81a-39c1-202b-8a4a-00304854f801",
" rev": "1-49cdcc98dff1785f64a3d9fd02844601",
"taxonID": "fffaf81a-39c1-202b-8a4a-00304854f801",
"scientificName": "Allobates ranoides - Boulenger, 1918",
"scientificNameWithoutAuthorship": "Allobates ranoides",
"scientificNameAuthorship": "Boulenger, 1918",
"family": "Aromobatidae",
"taxonRank": "species",
"taxonomicStatus": "accepted",
"acceptedNameUsage": "Allobates ranoides - Boulenger, 1918",
"metadata":{
              "identifier": "fffaf81a-39c1-202b-8a4a-00304854f801",
              "type": "taxon",
              "created":1479335273,
              "modified":1479329397,
              "creator": "Jaime Alberto Gutierrez",
              "contributor": "Jaime Alberto Gutierrez",
              "contact": "jaimealbertogutierrez@gmail.com",
              "source": "User"}
```

Campo	Descripción
id	Identificador único de la Especie
_rev	Identificador del proceso de revisión
taxonID	Id del taxón asociado a la especie
scientificName	Nombre científico nominal de la Especie
	Nombre científico de la especie sin autor
scientificNameWithoutAuthorship	asociado
	Nombre científico dado por el investigador
scientificNameAuthorship	autor
	Familia taxonómica a la que se asocia la
family	especie
taxonRank	Rango del taxón

Sede Principal: Calle28A#15-09 Bogotá, D.C., Colombia | PBX: (57)(1) 3202767 | NIT 820000142-2





taxonomicStatus	Status taxonómico (aceptado o rechazado)
acceptedNameUsage	Nombre definido aceptado para la especie
	Identificador general de metadatos de
identifier	registro
type	Tipo (Especie, subespecie o derivación)
created	Fecha de creación del registro
modified	Fecha de modificación del registro
	Usuario responsable de la
creator	creación/modificación del registro
	Persona responsable de la catalogación de la
contributor	especie
	Correo electrónico o username de contacto
contact	del responsable del cargue
	Fuente primaria de origen de la información
source	de la especie

Dentro de la estructura de indización para cada registro, se presenta la forma del archivo de cargue masivo de Elastic, de la siguiente manera:

Sede Principal: Calle28A#15-09 Bogotá, D.C., Colombia | PBX: (57)(1) 3202767 | NIT 820000142-2





```
"type":"taxon",
"created":1479335273,
"modified":1479329397,
"creator":"Jaime Alberto Gutierrez",
"contributor":"Jaime Alberto Gutierrez",
"contact":"jaimealbertogutierrez@gmail.com",
"source":"User"},"rev":null
}
```

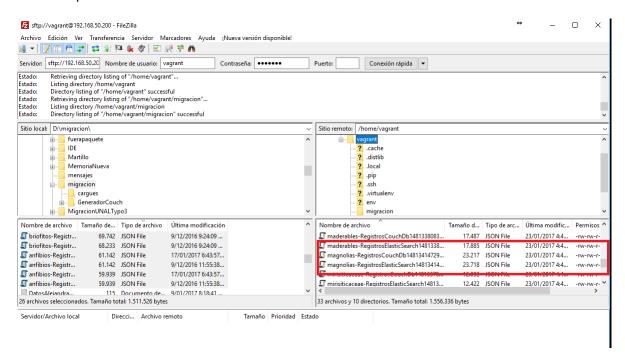
Que cómo se observa, comparte los campos comunes con el archivo de COUCHDB.





6. REALIZACIÓN DEL CARGUE AL AMBIENTE DE BASES DE DATOS NO RELACIONALES

Una vez se hayan realizado los procesos de generación de cargue de todas las bases para las familias de especies, el administrador debe realizar el cargue de los archivos mediante su herramienta favorita de SSH y administración remota de archivos. Se recomienda usar FILEZILLA para ello.



Una vez los archivos se encuentren cargados, se debe ingresar por la consola y realizar el proceso de cargue con los comandos CURL generados por el aplicativo de transformación y migración explicado en el punto 6.







Se debe ejecutar el primer comando para insertar los registros en la base de COUCHDB, así:

curl -X POST -d @mamiferos-RegistrosCouchDb1485204497115.json -H "Content-Type: application/json" http://admin:ncc123x@192.168.50.200:5984/mamiferos/_bulk_docs

Se deberá generar en pantalla una salida de la siguiente manera:

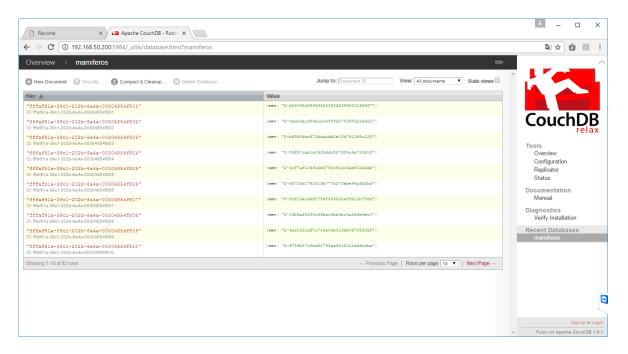




Para verificar, ingresar por FUTON y validar los documentos cargados en la base:







No obstante, hasta que no se realice la configuración del índice, los registros no serán visibles desde la aplicación de CHECKLIST, tal como se ilustra a continuación:





Recorte ➤ Usuário: Jaime Gutierrez. ➤ Recorte: MAMIFEROS. Recortes Famílias Logout FAMÍLIAS A B C Para realizar este proceso, con los registros de Elastic generados, debe procederse a ejecutar el comando que sigue: E posh~git~ nuvem [master] vagrant@cncfloralocal:~\$ curl ~XPOST 192.168.50.200:9200/mamiferos/_bulk -- ^ data-binary @mamiferos-RegistrosElasticSearch1485204497115.json

El cual debe generar el siguiente resultado luego del cargue:





Lo cual, al validar en la aplicación de CHECKLIST, ya debe permitir visualizar los datos cargados:

- > Usuário: Jaime Gutierrez
- >Recorte: MAMIFEROS.

Recortes Famílias Logout

FAMÍLIAS



Sede Principal: Calle28A#15-09 Bogotá, D.C., Colombia | PBX: (57)(1) 3202767 | NIT 820000142-2



Elaboró: Ingeniero JAIME ALBERTO GUTIÉRREZ MEJÍA CONSTRATISTA INSTITUTO ALEXANDER VON HUMBOLDT DICIEMBRE 2016

Sede Principal: Calle28A#15-09 Bogotá, D.C., Colombia | PBX: (57)(1) 3202767 | NIT 820000142-2